

# Cool Compiler Project

## Integrantes

- [Joel David Hernández Cruz](#)
- [Juan José Roque Cires](#)
- [Julio César Sánchez García](#)

## Content

Development Status.

Compiler Stage	Python Module	Status
Lexical Analysis	<a href="#">lexer.py</a>	complete
Parsing	<a href="#">parser.py</a>	complete
Semantic Analysis	<a href="#">semantic_analizaer.py</a>	complete
Code Generation	<a href="#">mips_generator.py</a>	complete

## Lexer & Parser

El proyecto esta desarrollado en python, para el desarrollo del lexer y el parser usamos la herramienta de parsing **ply**, que es una implementación de **Lex** y **Yac** originales de **C**, en python.

### Grámatica

La Grámatica usada es libre de contexto y de recursión extrema izquierda, los problemas de ambigüedad que esto puede traer, se resuelven luego en el parser, definiendo ciertas reglas de presedencia para los tokens. Ejemplo:

```
precedence = (  
    ('left', 'PLUS', 'MINUS'),  
    ('left', 'TIMES', 'DIVIDE'),  
)  
  
# Esta declaracion define que PLUS/MINUS tienen el mismo nivel de presedencia y son  
# asociativos a la izquierda, al igual que TIMES/DIVIDE. Dentro de esta declaracion los  
# tokens son ordenados de baja a alta presedencia, luego esta declaracion definiria que  
# TIMES/DIVIDE tienen un mayor nivel de presedencia que PLUS/MINUS
```

```
<program> ::= <classes>  
  
<classes> ::= <classes><class>;
```

```

| <class>;

<class> ::= class TYPE <inherits> { <features_list_opt> }

<inhertits> ::= inherits TYPE
| <empty>

<features_list_opt> ::= <features_list>
| <empty>

<features_list> ::= <features_list> <feature> ;
| <feature> ;

<feature> ::= ID ( <formal_params_list_opt> ) : TYPE { <expression> }
| <formal>

<formal_params_list_opt> ::= <formal_params_list>
| <empty>

<formal_params_list> ::= <formal_params_list> , <formal_param>
| <formal_param>

<formal_param> ::= ID : TYPE

<expr> ::= ID <- <expr>
| <expr>.ID( <arguments_list_opt> )
| <expr>@TYPE.ID( <arguments_list_opt> )
| <if>
| <while>
| <block_expr>
| <let>
| <case>
| new TYPE
| isVoids <expr>
| not <expr>
| <expr> + <expr>
| <expr> - <expr>
| <expr> * <expr>
| <expr> / <expr>
| ~ <expr>
| <expr> < <expr>
| <expr> <= <expr>
| <expr> = <expr>
| <comment>
| ( <expr> )
| SELF
| ID
| STRING
| TRUE
| FALSE
| INTEGER

<arguments_list_opt> ::= <arguments_list>

```

```

| <empty>

<arguments_list> ::= <arguments_list_opt>, <expression>
| <expression>

<case> ::= case <expression> of <case_actions> esac

<case_action> ::= ID : TYPE => <expr>

<case_actions> ::= <case_action>
| <case_action> <case_actions>

<let_expression> ::= let <formal_list> in <expression>

<formal_list> ::= <formal_list>, <formal>
| <formal>

<formal> ::= ID : TYPE <- <expression>
| ID : TYPE

<while> ::= while <expr> loop <expr> pool

<if> ::= if <expr> then <expr> else <expr> fi

<block_expr> ::= { <block_list> }

<block_list> ::= <block_list> <expr> ;
| <expr> ;

<empty> ::=

```

## Lexer

Para la implementación del lexer, definimos una lista de tokens, que define todos los posibles nombres que pueden tomar los tokens. Esta lista también es usada más adelante para identificar los terminales a la hora de parsear. Cada token está especificado por una expresión regular compatible con el módulo **re** de Python. Ejemplo:

```

tokens = (
    'NUMBER',
    'PLUS',
)
# El nombre que le sigue a t_ debe machear exactamente con el del token correspondiente
t_PLUS = 'r\+'

# Para expresiones mas complejas la regla puede definirse como un metodo.
def t_NUMBER(t):
    r'\d+'
    t.value = int(t.value)
    return t

```

En el lexer definimos varios estados internos, para que en ciertos casos use diferentes reglas, tokens, etc.. Este es el caso para los **Strings** y los **Comentarios**. Para definir un nuevo estado del lexer primero debemos declararlo:

```
@property
def states(self):
    return (
        ("STRING", "exclusive"),
        ("COMMENT", "exclusive")
    )
```

Estos pueden tener dos tipos, **exclusive** e **inclusive**, en el 1ro se sobrescribe por completo el comportamiento del lexer, es decir el lexer solo aplicara reglas y retornara tokens definidos para este estado. El **inclusive** simplemente anade reglas nuevas a las ya existentes. Luego para tokenizar strings y comentarios usamos los estados especiales definidos para ellos, y luego regresamos al estado por defecto.

Para el manejo de errores al tokenizar, ply ofrece varias facilidades para reportarlos.

```
def t_error(self, t):
    ...
    print("Illegal character! Line: {0}, character: {1}".format(t.lineno,
t.value[0]))
    ...
# Donde t.lineno seria el numero de la linea donde se encontro el error.
# Y t.value[0] el caracter que provoco este trigger.
```

## Parser

Para la implementación del parser, hacemos uso de **ast.py**. Cada regla de la gramática la definimos en Python, donde el docstring de la función contiene la especificación de la gramática libre de contexto correspondiente. Ejemplo:

```
# Ejemplo de uso
def p_class(self, parse):
    """
    class : CLASS TYPE LBRACE features_list_opt RBRACE
    """
    parse[0] = AST.Class(name=parse[2], parent="Object", features=parse[4])
```

Como mencionamos anteriormente, los problemas de ambigüedad son resueltos por el parser al definir precedencia entre los operadores, el funcionamiento de esta, lo explicamos anteriormente con un ejemplo mas sencillo.

```
# precedence rules
precedence = (
    ('right', 'ASSIGN'),
    ('right', 'NOT'),
    ('nonassoc', 'LTEQ', 'LT', 'EQ'),
    ('left', 'PLUS', 'MINUS'),
    ('left', 'MULTIPLY', 'DIVIDE'),
    ('right', 'ISVOID'),
    ('right', 'INT_COMP'),
    ('left', 'AT'),
    ('left', 'DOT')
)
```

Para el manejo de errores al igual que en el lexer **ply.yacc** ofrece varias facilidades para reportarlos.

```
def p_error(self, parse):
    """
    Error rule for Syntax Errors handling and reporting.
    """
    if parse is None:
        error = "Error while trying to parse None... Unexpected end of input!"
        self.error_list.append(error)
    else:
        error = f"Syntax error! Line: {parse.lineno}, position: {parse.lexpos},
character: {parse.value}, type: {parse.type}"
        self.error_list.append(error)
        self.parser.errok()
# parse.line -> # de la linea
# parse.lexpos -> posicion relativa del caracter en el texto
# parse.value -> valor del caracter
# parse.type -> terminal
```

## Análisis Semántico

Para el análisis semántico seguimos un patrón **visitor**. Todo el chequeo semántico se resuelve en una sola pasada. Realmente no todo, porque se realiza un precómputo para resolver los tipos disponibles, así los métodos y atributos de cada uno pero realmente es  $O(N)$  siendo  $N$  la cantidad de tipos que se definen.

Luego es necesario recalcar observaciones que tuvimos, de las cuales algunas no se especifican en el manual de COOL.

- Si un método tiene como tipo de retorno **SELF\_TYPE** su body tiene que retornar **SELF\_TYPE** también. La razón para esto es para hacer un compilador más Seguro para el Programador. Ya que puede generar problemas más que visibles como:

```
class Animal{
    copy(): SELF_TYPE {new A};
};

class Perro : Animal{

};
```

Al intentar `p : Perro <- (new Animal).copy()` esto es un error semántico ya que se intenta almacenar en una variable más específica un objeto más general.

- Chequeamos errores de herencia cíclica así como la imposibilidad de heredar de `Int`, `Bool`, `String`.
- Asociamos a cada nodo de AST su tipo estático que será de utilidad en tiempo de compilación.

## Generación de Código

### Cool -> Cil

Primero destacar que no nos mantenimos fieles al cien por ciento al CIL del Libro de Compilación de Piad, basándonos en ese diseñamos un IL que pensamos que nos sería útil.

En la traducción a CIL resolvemos varios problemas.

- Renombramiento de variables y los labels necesarios para cada salto en MIPS, esto último fue debido a que el objetivo era que el tránsito CIL -> MIPS debería ser lo más sencillo posible.
- De la sencillez de CIL a MIPS, deriva que no tenemos un árbol CIL, si no una lista que se recorrería en orden y se transpilaría nodo a nodo, no todo nodo CIL tiene representación escrita.
- Uno de los temas más interesantes que nos encontramos aquí fue la resolución de *case* y un convenio para contruir los objetos, de esto último hablaremos más abajo, para la resolución de los *case* primero se ordena cada acción con el siguiente criterio, quien más específico sea, para luego a través de una función *inherits* saber si el tipo de la expresión del *case* hereda del tipo de la acción. Luego la pregunta sería como se define la función *inherits*. Sencillo con un DFS por los tipos disponibles marcamos para cada tipo el momento de entrada en el DFS y el momento de salida, luego se puede afirmar que  $T_1 < T_2$  si *llegada*  $T_1 > \textit{llegada } T_2$  y *salida*  $T_1 < \textit{salida } T_2$ .
- El otro punto, los constructores tratamos de diseñarlos como pensamos que lo haría C#, un método que se le agrega en esta fase a cada clase, con nombre igual al de la clase, donde el body serían las asignaciones que se definen en los atributos. De esa manera crear un objeto se resuelve como un dispatch normal y no importa el orden en que se definan las clases, ni si una clase tiene como atributo un objeto de otra clase.
- Recopilamos todos los **String** que se definen en el código.
- Construimos el `.Type`, donde en cada tipo se guarda la información del DFS, el nombre del tipo para el `type_name` y las funciones que se definen para cada tipo con la invariante: Si  $T_1 < T_2$  para todo método de  $T_2$  si es el *i*-ésimo en su tabla virtual, también será el *i*-ésimo en la de  $T_1$ .

### Cil -> Mips

La generación de MIPS se divide en 3 partes fundamentales:

1. Crear el constructor de la clase `Main`. Que será el punto de entrada al programa.
2. **dotCode** donde se encuentran todo el código del programa
3. **dotData** donde se encuentran todas las definiciones de los strings

En Mips seguimos nuestro propio convenio, y trabajamos casi todo en pila. El siguiente convenio fue estudiado en **Programacion de Maquina**, cada llamado a funcion( un **dispatch**), pusheamos en la pila el valor de los registros `$fp` y `$ra` y estos son los unicos registros que salvamos, luego movemos el valor de `$sp` a `$fp` para simular una pila vacia, y al regresar del llamado realizamos la operacion contraria.

Usamos el registro `$fp` para acceder a los argumentos y a los locales en un metodo, a la derecha de `$fp` estan los argumentos y a la izquierda las locales.

A los tipos basicos [Int, String, Boolean] se les hace boxing y unboxing. Aclarar que al ser pasados como argumento se les hace una copia del valor no del tipo.

La tabla de metodos para cada tipo, se lleva en mips, donde a cada tipo se le asigna una direccion estatica, y a partir de ahi se colocan punteros a los metodos que estas definen.

## Ejecutando el proyecto

---

En el proyecto incluimos un virtual enviornment, por lo que no es necesario instalar ninguna dependencia para correrlo, en **coolc.sh** activamos el enviornment y corremos el proyecto con los casos de pruebas especificados.

```
$ ./coolc.sh <input_file.cl>
```